

Детализация пространства в поэзии XX века

Орехов Борис Валерьевич

НИУ Высшая школа экономики, г. Москва

Работа с корпусом

Корпус

Поэтический

• 107 811 текстов • 14 477 581 слово

Подкорпус

Задать

Поиск точных форм

Лексико-грамматический поиск

Поиск учитывает:


- ☒ все разборы
- ☐ предпочтительные разборы



Слово 1



Лемма



<https://ruscorpora.ru/search?search=CgQyAggJ>

Грязные данные

Уникальных LOC-сущностей: 56444, 129855 вхождений

```
from natasha import (  
    Segmenter,  
    NewsEmbedding,  
    NewsNERTagger,  
    MorphVocab,  
    Doc  
)
```

Топ-5 географических сущностей по числу документов:

России: 1381 документов, формы: ['России']

Москва: 1101 документов, формы: ['Москва']

Россия: 1031 документов, формы: ['Россия']

Из: 849 документов, формы: ['Из']

Москве: 724 документов, формы: ['Москве']

Пример данных

Автор: С. С. Бобров

Текст: Столетняя песнь, или торжество осьмогонадесять века России : «Глубока ночь! — а там — над бездной...»

Форма: России

Дата: 1801

Путь: xix/1790-1810_poets/poets-009

Автор: С. С. Бобров

Текст: Торжественный день столетия от основания града св. Петра : «Кто там, подобная деннице...»

Форма: России

Дата: 1808.05.16

Путь: xix/1790-1810_poets/poets-013

Автор: А. Ф. Воейков

Текст: Сатира к С«перанскому» об истинном благородстве : «С«перанский», друг людей, полезный гражданин...»

Форма: России

Дата: 1806

Путь: xix/1790-1810_poets/poets-102

Преобразование данных

Восстановлено normal-форм: 129855 (pymorphy2)

После слияния: 24041 уникальных LOC-сущностей

'Москвы' -> 'москва' | П. П. Сумароков | Чудеса : «Видал я на своем веку чудес немало...» | 1804

'Москвы' -> 'москва' | А. И. Тургенев | Стихи, сочиненные дорогой из Москвы в Петербург : «Вотще невежество свой грубый глас возносит...» | 1796

'Москвы' -> 'москва' | С. А. Ширинский-Шихматов | Пожарский, Минин, Гермоген, или Спасенная Россия. Песнь третья : «Сверкаючи кристаллом чистым...» | 1807

'Москвы' -> 'москва' | Н. М. Шатов | Пожар Москвы 1812 году : «Пою пожар Москвы несчастной!...» | 1813-1814


Wikipedia: фильтр и координаты

Осталось: 1736

москва	2729 док. (55.7506, 37.6175)
нева	614 док. (59.9447, 30.3094)
волга	466 док. (45.6972, 47.8625)
петербург	443 док. (59.9500, 30.3167)
крым	338 док. (45.4000, 34.0000)
ленинград	302 док. (59.9500, 30.3167)

+ слияние по координатам (Ленинград + Петербург), слилось в одну запись: 49

Топ-10 географических сущностей по числу документов




Топ-10 до слияния по координатам

Результаты


Корпус целиком

Топ-15 географических сущностей по числу документов




Топ-20 связей (без Москвы)

нева — петербург 86
днепр — киев 41
петербург — сибирь 25
англия — франция 25
сибирь — урал 24
волга — сибирь 24
волга — урал 23
крым — одесса 22
волга — кама 22
петербург — польша 20




Плотность географического распределения LOC-сущностей



Весь корпус

Плотность географического распределения LOC-сущностей:
европейская часть России




Европейская часть России, весь корпус

Авторы


author	unique_entities	docs	with_loc
В. Я. Брюсов	149	1690	194
В. В. Маяковский	142	634	214
Е. А. Евтушенко	121	344	113
Н. А. Клюев	119	571	153
И. А. Бродский	114	693	143
Д. Л. Андреев	113	452	96
В. А. Жуковский	110	696	127
К. М. Симонов	109	282	88

author	unique	docs	with_loc
С. Л. Геевский	1	16	16
А. Я. Кульчицкий	6	30	29
Н. А. Степанов	1	15	4
С. Д. Дрожжин	10	178	40
К. Эрберг	3	70	12
Андрей Белый	29	505	103
А. А. Ахматова	58	931	176
...			
Я. В. Смеляков	52	371	117

Топ-15 авторов по числу уникальных LOC-сущностей



Анти топ-15 авторов (≥ 10 док.), избегающих LOC



Пространство во времени

Динамика во времени

Десятилетие	Уникальных сущностей	Всего вхождений
1800-е	87	228
1810-е	134	399
1820-е	246	890
1830-е	269	1184
1840-е	222	779
1850-е	124	330
1860-е	190	573
1870-е	147	367
1880-е	87	181
1890-е	112	237
1900-е	217	586
1910-е	447	2021
1920-е	632	3360
1930-е	529	2307
1940-е	379	1758
1950-е	347	1314

Корреляция между уникальными сущностями и вхождениями

Пирсон: $r = +0.9696$, $p = 2.849e-19$


Спирмен: $\rho = +0.9909$, $p = 7.859e-27$

Кендалл: $\tau = +0.9375$, $p = 1.408e-13$


Все три коэффициента корреляции — **очень высокие** (0.94–0.99) и **статистически значимые** (p-значения порядка 10^{-13} – 10^{-27})

Эпохи «топонимического богатства» совпадают с эпохами «топонимической активности».

ЛОС-сущности по десятилетиям: уникальные vs. все вхождения




Географическое распределение LOC-сущностей: 1760-е
Уникальных сущностей: 59, вхождений: 117




XVIII век

Географическое распределение LOC-сущностей: 1860-е
Уникальных сущностей: 190, вхождений: 444




XIX век


Географическое распределение LOC-сущностей: 1910-е
Уникальных сущностей: 447, вхождений: 1852




Географическое распределение LOC-сущностей: 1920-е
Уникальных сущностей: 632, вхождений: 3067




Европейская часть России, 1820-е
Уникальных сущностей: 94, вхождений: 356




Европейская часть России, 1830-е
Уникальных существ: 125, вхождений: 604




Европейская часть России, 1890-е
Уникальных сущностей: 44, вхождений: 108




Европейская часть России, 1890-е
Уникальных сущностей: 44, вхождений: 108




Европейская часть России, 1900-е
Уникальных сущностей: 79, вхождений: 285




Европейская часть России, 1910-е
Уникальных существ: 186, вхождений: 993




Европейская часть России, 1920-е
Уникальных существ: 264, вхождений: 1667



Европейская часть России, 1930-е
Уникальных существ: 232, вхождений: 1110



Плотность географического распределения LOC-сущностей:
Пермский край




Насколько геолексика обычная?


Сводная таблица

decade	n_docs	n_tokens	n_types	ttr	msttr	entropy	loc_unique	loc_occurrences
1820-e	2730	748617	87912	0.117433	0.701539	13.142498	246	890
1830-e	4945	976988	96309	0.098577	0.681685	13.009756	269	1184
1840-e	2521	661585	83852	0.126744	0.679929	12.982542	222	779
1850-e	1983	347781	60752	0.174685	0.697646	12.976899	124	330
1860-e	1675	387569	64520	0.166474	0.668832	12.850369	190	573
1870-e	1076	261365	54719	0.209359	0.695008	13.000819	147	367
1880-e	1970	263563	48052	0.182317	0.692418	12.771146	87	181
1890-e	2881	305099	49778	0.163154	0.695505	12.821581	112	237
1900-e	7453	715270	90783	0.126921	0.699361	13.310785	217	586
1910-e	12635	1187693	145825	0.122780	0.719268	13.746636	447	2021
1920-e	12094	1484117	185510	0.124997	0.723382	13.951992	632	3360
1930-e	8422	1041434	145547	0.139756	0.713607	13.726292	529	2307

MSTTR vs LOC: $r = +0.582$, $p = 0.000597$



ENTROPY vs LOC: $r = +0.829$, $p = 8.61e-09$



Рост LОС в основном объясняется
ростом корпуса.

Но в десятилетия, когда язык поэзии
лексически богаче, географических
сущностей тоже больше, независимо
от размера корпуса.