

Опыт создания башкирских электронных филологических ресурсов

Стандарты, разметка, обвязка

Борис Орехов, НИУ ВШЭ



Два проекта на материале башкирского языка

Башкирский поэтический корпус

17 895 стихотворений XX века — с морфологической и метрической разметкой. Охватывает 1,77 млн словоупотреблений и представляет весь спектр башкирской поэзии ушедшего столетия.

ЭНИ «Фольклорный архив БашГУ»

Полнотекстовая коллекция фольклорных записей **с 1940-х годов по настоящее время** — впервые вводящая архивные материалы в широкий научный оборот.



Принципы электронной публикации

Текстологическая строгость



- Тексты публикуются в том виде, в каком они зафиксированы в архиве
- Редакторская и литературная правка не производится — за исключением явных ошибок
- Сохраняются орфография и пунктуация источников
- Применяются нормы текстологии, выработанные для академического издания

Стандарт TEI: фундамент цифровой филологии



Рекомендован сообществом

Text Encoding Initiative — принятый научным сообществом стандарт для электронных филологических публикаций.



Машиночитаемость

Обеспечивает автоматическую обработку текстов и интеграцию с исследовательскими инструментами.



Долговременная сохранность


Гарантирует переносимость данных между платформами и защищает от привязки к конкретной программной реализации.

Отличие от Фундаментальной электронной библиотеки

ФЭБ — оцифровка изданного

Фундаментальная электронная библиотека воспроизводит печатную версию.

Фольклорный архив Башкирского государственного университета



ЭНИ БашГУ — введение нового

Архивные записи фольклора, до сих пор доступные лишь узкому кругу специалистов, впервые вводятся в широкий научный оборот. Электронная форма не дублирует печатную — она **создаёт новый источник**.

Обязка: сервисы для исследователя

Совокупность навигационных и поисковых инструментов, превращающих электронное хранилище в рабочую исследовательскую среду.

1

Интерактивное оглавление

Сортировка по заглавию, жанру, году и месту записи — многомерный доступ к коллекции.

2

Указатель словоформ

Автоматически составляемый индекс с данными о частотности каждой словоформы в корпусе.

3

Интерактивные карты

Визуализация географии фольклорных записей на основе Google Maps с точными координатами мест сбора материала.

Указатель словоформ. Контексты слова «дунғыз»


Ахмулла Бәйте (байт), 1964 г.

...Ахмулланың ғәзиз башын Дәүләй **дунғыз** үлтергән. ...

Обновлено: 25.3.2014

- Нам все равно, - тип.

Жандармдар уларҙы хулға алғандар, ти.



Ссылка на эту публикацию:

Өкәт [Электронный документ] // Фольклорный архив Башкирского государственного университета: электронное научное издание / под ред. Б. В. Орехова, А. А. Галлямова. [2011—2026]. Дата обновления: 25.10.2018. URL: <http://nevmenandr.net/pages/bashfolk.php?id=11> (дата обращения: 02.10.2026).

Дополнительные сервисы

Обязка



- Автоматически генерируемые таблицы и графики распределения текстов по районам и жанрам
- Автоматическое оформление библиографических ссылок в соответствии с ГОСТ 7.0.5-2008
- Конкорданс со статическими HTML-страницами для быстрого и предсказуемого поиска
- Возможность составления фольклорного и диалектологического атласа

VML — специализированный язык разметки

Verse Markup Language

Минималистичный язык разметки, разработанный специально для поэтических коллекций. Обеспечивает однозначное разграничение функционально различных частей стихотворного текста.

- Универсален и не привязан к конкретному естественному языку
- Не зависит от системы стихосложения
- Распространяется под свободной лицензией **Apache 2.0**



Б. В. ОРЕХОВ

Башкирский стих XX века

КОРПУСНОЕ
ИССЛЕДОВАНИЕ



Морфологическая и метрическая разметка текста

Собственный анализатор

Разработан на основе правил башкирской агглютинации — грамматический словарь и формализованное описание словоизменительной системы.

Масштаб корпуса

1,77 млн словоупотреблений — весь массив башкирской поэзии XX века охвачен автоматической обработкой.

122 600 «неуверенных» разборов

Имена собственные и заимствования — зоны, требующие дополнительной верификации и ручной коррекции.


Риски утраты архивных материалов



Оцифровка и сохранение

- Диалектный архив башкирских экспедиций исчез
- Русский фольклорный архив едва не был выброшен в мусор
- Оцифровка дает возможность сохранить то, что может оказаться ситуативно лишним
- Реальные случаи показывают необходимость срочной оцифровки архивов

Инфраструктурные угрозы для ресурсов



- Сервер ЭНИ отключался несколько раз, доступ извне сети университета стал невозможным
- Ресурс был перемещен на личный сайт автора (nevmenandr.net)
- Текущее размещение не является окончательным решением
- Необходима долговременная стратегия хостинга, резервного копирования и передачи ответственности

Оцифровка в эпоху LLM



- Языки с большим объемом электронных текстов получают преимущество в LLM
- Язык, представленный в цифровой среде фрагментарно, слабо представлен в моделях
- Это влияет на машинный перевод, справочные системы и другие технологии
- Упущенные возможности оцифровки ослабляют позиции языка в технологиях будущего

Выводы и рекомендации



Разметка

корпусный подход продуктивен
для миноритарных языков



Обязка

поисковые сервисы
превращают коллекцию в
исследовательский инструмент



Риски

оцифровка и
инфраструктурная поддержка
— условие сохранения
культурного наследия